Обоснование выбора модели машинного обучения

Аналитическая записка

Папин А.В., ИУ5Ц-31М
МГТУ им. Н.Э. Баумана, кафедра ИУ-5
19 октября 2026 г.

1. Постановка задачи

На этапе проектирования системы технического зрения мобильного робота нужно выбрать одну модель машинного обучения из нескольких готовых вариантов. Модели уже обучены, поэтому повторное обучение и сравнение на специально собранном датасете не являются основанием выбора. Требуется найти лучшую модель и доказать выбор объективно, опираясь прежде всего на архитектуру и вычислительные свойства кандидатов, а эксперимент использовать как подтверждение, а не как единственный аргумент.

К модели предъявляются жёсткие требования бортовой платформы: задержка не более 0,1 с, память весов не более 64 МБ, выход в виде рамок, детерминизм и возможность квантования. Дополнительно учитывается сопровождение объектов. Заранее неизвестно, в какой сцене будет работать робот, поэтому рассматриваются три состояния: 5, 20 и 50 объектов в кадре. Принципиальное условие — отсутствие субъективных весов, критерия Парето и экспертных оценок: каждая характеристика должна быть числом с формулой и единицами, а сведение — детерминированной процедурой, одинаковой для всех моделей.

2. Кандидаты и ограничения

Для сравнения взяты девять моделей, представляющих основные семейства детекторов: одностадийные YOLO, двухстадийные Faster R-CNN и Mask R-CNN, трансформер RT-DETR, рекуррентная схема CNN+LSTM и сегментационная YOLO11n-seg. Такой набор позволяет проверить методику на разных архитектурах, а не только на моделях одного семейства. Все кандидаты предобучены и доступны в открытых реализациях, поэтому их параметры и вычислительная стоимость известны до начала расчёта.

Фильтры отсекают модели, которые физически не соответствуют требованиям борта. Порог по задержке составляет 0,1 с, по памяти — 64 МБ; дополнительно проверяются тип выхода, детерминизм, квантование и сопровождение. Задержка в данной работе берётся из аналитической оценки, а не из измерения на конкретном железе. Это сознательно консервативная оценка, которая должна гарантировать работоспособность в худшем сценарии.

Таблица 1. Кандидаты и результаты фильтрации

Модель	Семейство	P, млн	F, Г	mAP, %	T, с	M, МБ	Выход	Фильтр
YOLO11n	1-stage CNN	2,62	6,6	39,5	0,066	10,5	рамка	проходит
YOLOv8n	1-stage CNN	3,16	8,9	37,3	0,089	12,6	рамка	проходит
YOLO11s	1-stage CNN	9,46	21,7	47,0	0,217	37,8	рамка	нет: T
YOLOv8s	1-stage CNN	11,17	28,8	44,9	0,288	44,7	рамка	нет: T
RT-DETR-l	transformer	32,0	103,5	53,0	1,04	128	рамка	нет: T, M
Faster R-CNN	2-stage CNN	41,5	180	37,4	1,80	166	рамка	нет: T, M
Mask R-CNN	2-stage CNN	44,2	250	—	2,50	177	маска	нет: T, M, выход
YOLO11n-seg	1-stage CNN	2,9	9,8	—	0,098	11,6	маска	нет: выход
CNN+LSTM	CNN + рекуррент.	3,15	6,61	39,5	0,070	12,6	рамка	проходит

После фильтров остаются YOLO11n, YOLOv8n и CNN+LSTM. YOLO11s и YOLOv8s отсеиваются по задержке: 0,217 и 0,288 с больше 0,1 с. RT-DETR-l и Faster R-CNN не проходят по задержке и памяти, Mask R-CNN дополнительно имеет масочный выход. YOLO11n-seg проходит по времени и памяти, но выдаёт маску, поэтому при требовании «рамка» исключается. Если бы задача требовала масок, набор финалистов и дальнейшая процедура изменились бы. В расчётном скрипте используется семь моделей: две сегментационные исключены заранее по типу выхода; на итоговый список финалистов это не влияет.

3. Характеристики модели

Введены пять основных характеристик, отражающих разные стороны пригодности: эффективность, читаемость, различимость, однозначность класса и наглядность. Каждая вычисляется по формуле из параметров архитектуры и имеет единицы измерения. Дополнительно используются ресурсные характеристики, напрямую связанные с работой на борту.

Эффективность E показывает, сколько вычислений требуется модели на кадр: $E = 1/F$, где F — число FLOPs. Чем меньше F, тем выше E; единица измерения — 1/Гфлоп. Читаемость C отражает сложность структуры: $C = \tau / \log_2(P + 1)$, где P — число параметров в миллионах, $\tau = 1$ для свёрточных

сетей и $\tau = 0{,}5$ для трансформеров. Характеристика безразмерная; рост числа параметров снижает её логарифмически, а не линейно.

Различимость R оценивает способность модели разделять классы через VC-размерность: $R \approx VCdim = O(W \cdot L \cdot \log W)$, где W — число весов, L — глубина сети. Единица измерения — число областей; большее значение означает более высокую ёмкость, но не гарантирует лучшую точность на конкретных данных. В таблицах VCdim приведена в единицах 10^{-9}. Это архитектурная оценка, а не измеренная точность.

Однозначность класса O для однозначной классификации с softmax и argmax равна 1; для мультиметки $O = 1/k$, где k — число классов на один объект выхода. Характеристика безразмерная. В данном наборе все финалисты используют однозначный выход, поэтому O = 1 у всех трёх и не различает модели. Наглядность $H = 1 / \log_2(k + 1)$, где k — число одновременно выводимых сущностей; для k = 80 получается $H \approx 0{,}157$. Она также одинакова у финалистов и включена для полноты описания, а не для ранжирования.

Ресурсные характеристики: P — число параметров, млн; F — число операций, Гфлоп; $M \approx 4P$ — память весов float32, МБ; $T = F / \Pi$ — аналитическая задержка, с; $f = 1/T$ — частота, Гц. Расчётная производительность платформы принята $\Pi = 100$ Гоп/с. Эти величины связаны между собой, поэтому образуют согласованный набор, а не пять независимых оценок.

Таблица 2. Основные характеристики модели

Характеристика	Формула	Единицы	Что показывает
Эффективность E	$E = 1/F$	1/Гфлоп	меньше вычислений — эффективнее
Читаемость C	$C = \tau / \log_2(P + 1)$	безразм.	проще структура — читаемее
Различимость R	$R \approx VCdim = O(W \cdot L \cdot \log W)$	шт.	ёмкость разделения классов
Однозначность O	O = 1 (softmax + argmax); 1/k для мультиметки	безразм.	однозначность выбора класса
Наглядность H	$H = 1 / \log_2(k + 1)$	безразм.	простота интерпретации выхода

Таблица 3. Значения характеристик финалистов

Модель	P	F	M	T	f	E	C	VCdim·10^{-9}	O	H	Ф
YOLO11n	2,62	6,6	10,5	0,066	15,2	0,152	0,047	10,1	1	0,157	**0,875**
YOLOv8n	3,16	8,9	12,6	0,089	11,2	0,112	0,046	8,8	1	0,157	0,182
CNN+LSTM	3,15	6,61	12,6	0,070	14,3	0,151	0,046	12,3	1	0,157	0,484

YOLO11n имеет наименьшие P, F, M и T и наибольшую E. CNN+LSTM близок по E и F, имеет более высокую VCdim, но требует больше памяти и работает медленнее. YOLOv8n уступает YOLO11n по эффективности и задержке, хотя немного превосходит по VCdim. Одинаковые O и H не влияют на выбор; основной вклад дают E, C, VCdim и ресурсные характеристики.

4. Методика расчёта

Сцена заранее неизвестна, поэтому модель сравнивается в трёх состояниях: 5, 20 и 50 объектов. Для каждой модели и сцены вычисляется выигрыш $f(i,j) = \Pi / (F(i) + \alpha \cdot N(j)^2)$, где $\Pi = 100$ Гоп/с, $\alpha = 0{,}001$ Г, N(j) — число объектов. Квадратичный член отражает рост стоимости постобработки, сопровождения и проверки гипотез при увеличении числа объектов. Выигрыш измеряется в герцах и показывает, сколько кадров в секунду модель обрабатывает в данной сцене.

Сведение выполняется без весов. Каждая характеристика нормируется min–max к отрезку [0, 1] с учётом направления: для «больше — лучше» используется прямое значение, для «меньше — лучше» — обратное. Затем вычисляется Ф как среднее нормированных характеристик. Дополнительно рассчитываются число Борда и средний ранг; они не заменяют Ф, а проверяют, что результат не является следствием одной свёртки.

Для принятия решения в условиях неопределённости используются пять классических критериев. Лаплас берёт среднее по сценам, оптимизм — максимум, Вальд максимизирует худший результат, Сэвидж минимизирует сожаление относительно лучшего результата в каждой сцене, Гурвиц объединяет максимум и минимум с коэффициентом α. Все критерии детерминированы и не требуют вероятностей сцен.

Набор из 22 способов включает пять критериев, балльный подсчёт, семь ресурсных показателей (η, EDP, ρ, BF, Q1–Q4), четыре комбинированных показателя и шесть авторских метрик (DF, AR, APM, FPG, SR, IDD). Широкий набор нужен для проверки устойчивости: если разные способы сведения дают одну модель, результат не зависит от выбора конкретной метрики.

Таблица 4. Результаты пяти критериев

Критерий	YOLO11n	YOLOv8n	CNN+LSTM	Лучший
Лаплас (среднее)	13,46	10,24	12,76	YOLO11n
Оптимизм (максимум)	15,09	11,20	14,23	YOLO11n
Вальд (максимин)	10,99	8,77	10,53	YOLO11n
Сэвидж (мин. сожаление)	0,00	3,89	0,86	YOLO11n
Гурвиц (α·max + (1−α)·min)	13,04	9,99	12,38	YOLO11n

Все пять критериев указывают на YOLO11n, причём преимущество сохраняется и в худшей сцене: по Вальду модель держит 10,99 Гц против 8,77 Гц у YOLOv8n и 10,53 Гц у CNN+LSTM. Это означает, что выбор не опирается на благоприятный сценарий и остаётся работоспособным при 50 объектах.

При сведении 22 способов нормированные значения дают Ψ = 0,955 для YOLO11n, 0,735 для CNN+LSTM и 0,045 для YOLOv8n. Число Борда составляет 64, 42 и 23, средний ранг — 1,045, 2,000 и 2,909. YOLO11n занимает первое место в 21 способе из 22; единственное исключение — метрика SR, которая характеризует масштаб семейства и не является оценкой пригодности конкретной модели. Совпадение трёх свёрток и 21 из 22 способов показывает, что результат устойчив.

5. Результаты аналитического расчёта

По совокупности характеристик и критериев выбрана YOLO11n. Её параметры: P = 2,62 млн, F = 6,6 Гфлоп, M = 10,48 МБ, T = 0,066 с, f = 15,15 Гц, Q = 0,66 Дж (энергия на кадр). В худшей сцене из 50 объектов модель сохраняет не менее 10,99 Гц, то есть обрабатывает кадр быстрее, чем требуется для управления роботом. Запас по задержке относительно порога 0,1 с составляет примерно 1,5 раза, по памяти — более чем в шесть раз.

Преимущество YOLO11n объясняется сочетанием факторов, а не одной выдающейся характеристикой. У неё наименьшие F и P среди финалистов, поэтому она лидирует по E и C; задержка также минимальна, а частота максимальна. По VCdim она уступает CNN+LSTM (10,1 против 12,3), но превосходит YOLOv8n (8,8). CNN+LSTM имеет близкую эффективность, однако требует больше памяти и работает медленнее. YOLOv8n уступает по эффективности и задержке, а преимущество по VCdim не компенсирует худшие P, F и T. Формально Ф у YOLO11n равен 0,875, у CNN+LSTM — 0,484, у YOLOv8n — 0,182; разрыв между первым и вторым местом значительно больше возможных колебаний при округлении исходных данных.

6. Экспериментальная проверка

Эксперимент проведён в Gazebo на четырёх синтетических сценах с 340 объектами разметки, в текстурированном кафе с 66 объектами и на реальном наборе COCO128 с 929 объектами. Сравнивались YOLO11n, YOLOv8s и YOLOv8n; метрика качества — mAP@0,5, дополнительно измерялась задержка. Синтетические сцены соответствуют целевым условиям, кафе проверяет перенос на другую текстурированную обстановку, COCO128 — на реальные изображения с более широким набором классов.

Таблица 5. Результаты эксперимента

Домен	YOLO11n	YOLOv8s	YOLOv8n
4 синтетические сцены, mAP@0,5	0,475	0,406	0,376
Кафе, mAP@0,5	0,402	0,435	0,478
COCO128, mAP@0,5	0,671	0,761	0,607

На синтетических сценах YOLO11n показывает лучший результат: 0,475 против 0,406 у YOLOv8s и 0,376 у YOLOv8n. Это подтверждает аналитический вывод для целевых условий. В кафе лучшей оказывается YOLOv8n (0,478), а YOLO11n опускается до 0,402; на COCO128 лидирует YOLOv8s (0,761), YOLO11n занимает промежуточное положение (0,671). Следовательно, на реальных данных большие модели могут быть точнее компактной YOLO11n.

Задержка YOLO11n составляет 19,7 мс, YOLOv8s — 51 мс, то есть по измерению YOLOv8s укладывается в 0,1 с. Аналитическая оценка для YOLOv8s по принятому профилю равна 0,288 с, что примерно в 5,6 раза выше измеренной. Это объясняется консервативностью модели производительности: П = 100 Гоп/с и линейная оценка T = F/П не учитывают реальную эффективность ядер и оптимизации. Для отсева это допустимо, поскольку оценка должна гарантировать худший случай, но при интерпретации важно помнить, что аналитическая задержка является верхней оценкой; при доверии натурному замеру YOLOv8s следовало бы вернуть в сравнение.

Эксперимент подтверждает выбор для синтетических сцен и заданных ограничений, но показывает доменную зависимость: на кафе и COCO128 лучшие модели меняются. Это не противоречит методике, поскольку она выбирает модель для заданных условий, а не «лучшую вообще». Если бы рабочая сцена совпадала с кафе, расчёт следовало бы дополнить данными этого домена; в текущей постановке целевыми являются синтетические сцены, и YOLO11n остаётся лучшей.

7. Обсуждение и ограничения

Аналитический расчёт и эксперимент отвечают на разные вопросы. Расчёт сравнивает модели по архитектурным и ресурсным свойствам при заданных ограничениях; эксперимент показывает, как предобученные веса работают на конкретных данных. Поэтому совпадение выводов на синтетических сценах и расхождение на кафе и COCO128 — ожидаемый результат, а не противоречие. На кафе и COCO128 большие модели могут использовать большую ёмкость и лучше подстраиваться под текстуры и классы, но их задержка и память выше. Методика выбирает не «самую точную», а «самую пригодную» модель при заданных ограничениях.

Выбор без весов и Парето означает, что ни одна характеристика не получает априорного преимущества. Если бы веса задавались вручную, результат можно было бы подогнать под желаемую модель; здесь этого нет. Пять критериев проверяют решение в разных предположениях о сцене, а 22 способа — в разных способах свёртки. Совпадение результатов важно не само по себе, а потому что показывает: вывод не зависит от одной формулы. Ограничение подхода в том, что он не заменяет измерение на всех доменах; он даёт обоснованный выбор до начала дорогих испытаний.

Практический смысл результата: для целевых синтетических сцен и ограничений $T \leq 0{,}1$ с, $M \leq 64$ МБ следует брать YOLO11n. Если рабочая обстановка смещается к кафе, разумно проверить YOLOv8n; если приоритет — точность на реальных изображениях и допустимо ослабить T, конкурентоспособна YOLOv8s. Если требуются маски, набор кандидатов нужно расширить сегментационными моделями. Таким образом, YOLO11n — не универсальный победитель, а лучшее решение в заданной постановке.

Часть характеристик является оценками, а не измерениями. VCdim и читаемость C вычисляются по архитектуре и не учитывают особенности конкретных весов; mAP в таблице кандидатов взят из предобученных моделей на COCO и не равен точности после дообучения. Поэтому аналитический расчёт следует рассматривать как отбор на этапе проектирования, а не как окончательное доказательство превосходства на всех данных.

Эксперимент покрывает пять YOLO-моделей, тогда как RT-DETR-l, Faster R-CNN и CNN+LSTM проверены только аналитически. Сегментационные модели исключены по типу выхода. Выборки ограничены: 340 объектов в синтетике, 66 объектов в кафе и 929 объектов в COCO128; кафе даёт небольшую выборку, поэтому его результат — качественный сигнал, а не точная оценка. Синтетические сцены отличаются от реальной обстановки, а COCO128 представляет другой набор классов. Наконец, пороги $T \leq 0{,}1$ с и $M \leq 64$ МБ являются требованиями конкретной платформы: при изменении производительности борта, разрешения камеры или числа классов фильтры и результат могут измениться, хотя сама методика сохраняется.

8. Заключение

Из девяти рассмотренных моделей после жёстких фильтров остались три, а аналитический расчёт по пяти характеристикам и ресурсным показателям выбрал YOLO11n. Модель имеет $P = 2{,}62$ млн, $F = 6{,}6$ Гфлоп, $M = 10{,}48$ МБ, $T = 0{,}066$ с и $f = 15{,}15$ Гц; она лидирует по всем пяти критериям, имеет $\Phi = 0{,}875$, $\Psi = 0{,}955$, число Борда 64 и средний ранг 1,045. Первое место сохраняется в 21 способе из 22.

Эксперимент в Gazebo подтвердил преимущество YOLO11n на целевых синтетических сценах: 0,475 mAP@0,5 против 0,406 у YOLOv8s и 0,376 у YOLOv8n. На реальных данных большие модели могут быть точнее, однако они требуют больше памяти и работают медленнее; по консервативной аналитической оценке они не проходят фильтры, хотя натурный замер YOLOv8s (51 мс) укладывается в 0,1 с. Полученный результат следует рассматривать как обоснованный выбор для заданных условий, а не как универсальное утверждение о превосходстве модели во всех доменах. Практическая рекомендация — использовать YOLO11n как базовую модель для целевых сцен и сохранить процедуру пересчёта на случай изменения задержки, памяти или требований к выходу.